

Filtrado en el Dominio de la Frecuencia

FFT directa, producto por la máscara del filtro y FFT inversa — ejemplos en R y Python

Dr. Marcelo Risk

Data Mining de Series Temporales · Maestría en Explotación de Datos y Descubrimiento de Conocimientos · FCEyN UBA · 2026

El filtrado en el DF se realiza en tres pasos

Un viaje de ida y vuelta entre dominios

1 • FFT directa

Transformar la serie temporal del dominio del tiempo (DT) al dominio de la frecuencia (DF).

```
fft(st)
```

2 • Producto en el DF

Multiplicar componente a componente la ST en el DF por el espectro (máscara) del filtro.

```
filtroDF * fft(st)
```

3 • FFT inversa

Volver al DT con la transformada inversa y verificar el resultado del filtrado.

```
Re(fft(·, inverse)/N)
```

Equivalencia clave: el producto componente a componente en el DF equivale a un producto de convolución de las series en el DT.

Características del filtrado en el DF

Qué gana y qué resigna frente al filtrado en el tiempo

✓ Ventaja: selectividad

Permite filtrados muy selectivos, imposibles de realizar en el DT.

La máscara puede recortar el espectro con precisión de un solo índice: conservar exactamente una frecuencia, o eliminar una banda angosta sin tocar a sus vecinas.

✗ Limitación: procesamiento offline

Es necesario tener toda la ST en memoria para calcular su FFT.

No sirve para procesamiento online (muestra a muestra, en tiempo real), donde los filtros del DT — como el de media móvil — siguen siendo la herramienta.

Regla práctica: selectividad quirúrgica sobre la serie completa → DF; procesamiento en flujo, muestra a muestra → DT.

Los tipos básicos de filtros en el DF

Cuatro máscaras ideales según qué banda dejan pasar



Pasa-bajos: conserva las frecuencias bajas: tendencias, ondas lentas.

Pasa-altos: conserva las altas: detalles rápidos; elimina DC y tendencias.

Pasa-banda: aísla una banda intermedia: un ritmo específico.

Elimina-banda: suprime una banda puntual: p. ej. interferencia de línea.

Generación de la línea de tiempo y las series

Tres senoidales, un nivel de DC y ruido gaussiano

R

```
N = 256
tiempo = 0:(N-1)
seno2 = 1*sin( 2*2*pi*tiempo/N)
seno10 = 1*sin(10*2*pi*tiempo/N)
seno20 = 2*sin(20*2*pi*tiempo/N)
nivelcdc = rep(1, N)
nivelruido = rnorm(N, mean=0,
                  sd=0.5)
```


PYTHON

```
import numpy as np
rng = np.random.default_rng(2022)
N = 256
t = np.arange(N)
seno2 = 1*np.sin( 2*2*np.pi*t/N)
seno10 = 1*np.sin(10*2*np.pi*t/N)
seno20 = 2*np.sin(20*2*np.pi*t/N)
nivelcdc = np.ones(N)
nivelruido = rng.normal(0, 0.5, N)
```

Lectura: k ciclos en N muestras aparecerán en el índice k del espectro (índice k+1 en R, que arranca en 1).

Las cinco componentes

Cada una vivirá en un lugar distinto del espectro



Dónde caerá cada una

seno2 → índice 2 (onda lenta).

seno10 → índice 10.

seno20 → índice 20, con el doble de amplitud:
será el pico dominante.

niveldc → índice 0 (frecuencia cero).

nivelruido → energía repartida en todos los
índices.

La serie combinada y su espectro

Paso 1: FFT directa de la suma de todas las componentes

R

```
seno21020dcruído = seno2 + seno10 +  
    seno20 + niveldc + nivelruido  
  
fft.st = fft(seno21020dcruído)  
  
par(mfrow = c(1, 2))  
plot(tiempo, seno21020dcruído, type='l')  
plot(Mod(fft.st), type='l')
```


PYTHON

```
st = (seno2 + seno10 + seno20  
    + niveldc + nivelruido)  
  
F = np.fft.fft(st)  
  
fig, ax = plt.subplots(1, 2)  
ax[0].plot(t, st)  
ax[1].plot(np.abs(F))
```

Mod() / np.abs() : la FFT devuelve números complejos; graficamos su módulo, el espectro de amplitud.

En el DT es una maraña; en el DF, cuatro picos

Cada componente quedó separada por frecuencia



El espejo: para una serie real, el espectro es simétrico — cada pico en el índice k se repite en $N-k$. Toda máscara deberá respetar esa simetría.

Diseño de la máscara del filtro

Paso 2: un pasa-altos que anula DC, seno2 y seno10

R

```
filtroDF = rep(1, N)
banda.filtro = 15

# anular indices bajos y su espejo
filtroDF[1:banda.filtro] = 0
filtroDF[(N-2-banda.filtro):N] = 0

fft.stDF = filtroDF * fft.st
```

PYTHON

```
filtroDF = np.ones(N)
banda = 15


# indices 0..14 y su espejo
filtroDF[:banda] = 0
filtroDF[N-banda+1:] = 0

F_filt = filtroDF * F
```

Atención a los índices: R indexa desde 1 y Python desde 0; en ambos, si se anula el índice k también debe anularse su espejo $N-k$.

La máscara y el espectro filtrado

El producto puso en cero todo lo que la máscara no deja pasar



Qué sobrevivió: solo el pico de seno20 (índice 20 y su espejo) y el ruido de alta frecuencia; DC, seno2 y seno10 desaparecieron.

Transformada inversa para volver al DT

Paso 3: reconstruir la serie y verificar el filtrado

R

```
stDF = Re(fft(fft.stDF,  
             inverse=TRUE) / N)  
  
plot(tiempo, stDF, type='l')  
lines(tiempo, seno20, col='red')
```


PYTHON

```
st_filt = np.real(np.fft.ifft(F_filt))  
  
plt.plot(t, st_filt)  
plt.plot(t, seno20, color='red')
```

Detalle de escala: `fft(., inverse=TRUE)` de R no divide por N — hay que hacerlo a mano; `np.fft.ifft` ya lo hace. `Re()/np.real` descarta residuos imaginarios numéricos.

Verificación: la serie filtrada contra seno20

La senoidal de 20 ciclos emergió de la maraña



Lo que queda: la serie filtrada sigue a seno20 con pequeñas irregularidades — es el ruido de alta frecuencia que la máscara pasa-altos también dejó pasar.

Ejercicios

A partir de la ST combinada, implementar un ejemplo de cada tipo básico

Pasa-bajos

Conservar niveldc y seno2; eliminar seno10, seno20 y el ruido rápido.

Pasa-altos

Variar banda.filtro y observar qué componentes van cayendo.

Pasa-banda

Aislar seno10: dejar pasar solo una banda angosta alrededor del índice 10.

Elimina-banda

Suprimir únicamente seno10 y conservar todo el resto de la serie.

En todos los casos: construir la máscara simétrica, multiplicar, antitransformar y superponer el resultado con la componente esperada.

Ideas para llevarse

Tres pasos

FFT directa $\rightarrow$ producto por la máscara $\rightarrow$ FFT inversa. El producto en el DF equivale a convolucionar en el DT.

Selectivo pero offline

Recorta el espectro con precisión de un índice, pero necesita toda la serie en memoria: no sirve online.

Cuatro máscaras básicas

Pasa-bajos, pasa-altos, pasa-banda y elimina-banda: todo se reduce a decidir qué índices valen 1 y cuáles 0.

Respetar el espejo

En series reales el espectro es simétrico: anular el índice k exige anular $N-k$, o la inversa deja de ser real.

Próximo paso: los ejercicios del TP — un filtro de cada tipo sobre la misma serie combinada.